
## Quetion1 报告

## 一、运行结果



## 二、讨论分析

Lshash 是一个实现局部敏感哈希的 python 包它的功能包括:

- 1. 通过使用 NumPy 数组的计算将高维数据快速哈希。
- 2. 支持多哈希索引
- 3. 内置通常的距离函数/排名输出

作业一要求通过对不同客户 vipno 进行哈希,通过比较 vipno 所购买 pluno 的情况,比较不同 vipno 的相似性,并通过改变 hash\_size 和 k 两个参数,观察其对结果的影响。

hash\_size 是要生成的哈希表的长度, k 值是对某个特定的输入, 查找出和它相似的结果的数量。

从结果中可以看到仅当 hash\_size = 2 时,k 取 1~5 都能够查询出结果;而当 hash\_size 取其他更大的值时,除了输入之外不能查询出别的结果。说明所给的数据,只能分出两组特征不同的簇,而对于 k 取 1~5 都能查询出结果,并不能看出两个簇分配的是否均匀,所以不妨将 k 取更大的值,并输出 result 的长度:

hash\_size:2, k:200, vipno:1590142151757, result: [159014216790, 1590142194632, 15951517576, result: [159014216790, 1590142194532, 15951532332332, 1590142192491, 1590142202978, 15901513002 69, 1591140691788, 2900000175648, 1590141216914, 1595151575662, 1590151784960, 29000002 24278, 29000001138613, 1595150991142, 1590151207971, 1595151786686, 1591150401421, 15910 16151613, 1593160596081, 2900000908079, 29000001333566, 1590142434362, 1595150512170, 29 00001465816, 2900002934007, 2900000756585, 1592131140216, 1595132864185, 2900001241540, 2900001229272, 1598140023120, 1590142517867, 159513031604, 2900002934288, 159514243218 9, 1591016150630, 1596160013077, 1590142190480, 1592015013285, 2900003114613, 159516019 4618, 2900000494273, 1591014756582, 2900000575899, 1590142519632, 290000014428, 29000041467100, 2900003115917, 2900002934236, 2900003109510, 1591016439575, 1591015457273, 159 1015088262, 1595142065844, 2900002936674, 29000003044, 1591040462983, 2900001432436, 1591014932061, 1592014001436, 1591030270772, 1590151103907, 159101338588, 159101545264 4, 1590142242059, 1591015592073, 290000311617, 1591040904970, 1591013884927, 290000293 4557, 2900000667914, 2900001452236, 1590151010026, 290000030863]

hash\_size:2, k:100, vipno:1590142151757, result: [159014216790, 1590142194532, 1595152332932, 1590142194491, 1590142202978, 15901513002 69, 1591140691788, 290000017648, 1590141216914, 1595151575662, 1590151784960, 2900002 24278, 290000118613, 1595150991142, 1590151207971, 1595151786686, 1591150401421, 15910 16151613, 1593160596081, 2900000968079, 2900001333566, 1590142434362, 1595150512170, 2900001465816, 2900002934007, 2900000765085, 1592131140216, 159513084185, 29000001241540, 2900001229272, 1598140023120, 1590142517867, 1595130381604, 2900002934298, 1595164243218, 1591016150630, 1596160013077, 1590142190480, 1592015013285, 2900003114613, 159516019 4618, 2900000849273, 1591014756582, 2900000575899, 1590142519632, 2900000144298, 290000 1467100, 2900003115917, 2900002934236, 29000003109510, 1591016495757, 1591015457273, 159101508262, 159514205844, 2900002934674, 2900000903944, 1591040462983, 2900001432436, 1591014932061, 1592014001436, 1591030270772, 1590151103907, 1591013368588, 159101545254, 1590142242059, 1591015592073, 2900003116167, 159104084970, 1591013368588, 159101545254, 1590142242059, 1591015592073, 2900003116167, 159104084970, 1591013368588, 2900003113500, 18033305699, 2900001452236, 1590151101026, 29000003030863]

可以看到当 k=100,200 时,其结果的长度都为 80,多次运行之后结果的长度都不会超过总的 vipno 的数目 298 的一半,也就是说明两个簇的分配是均匀的。

综上所述,得到结论:

- 1. 通过购买 pluno 的情况,只能获得两组具有不同特征的散列,所给数据特征数不充分
- 2. LSHash 得到的结果是均匀的