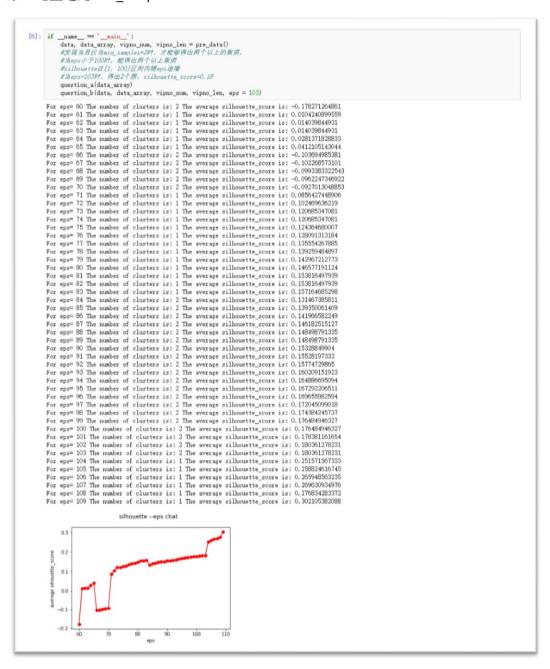
Question3 报告

一、结果

a) 第一问的结果:

为了能更清晰的看到结果,这里我把当 eps \in (60, 110)的 silhouette 结果逐条打印了出来,这里选定 min samples = 2



b) 第二问的结果:

这里将 DBSCAN 算法聚类之后得到的标签数组打印了出来,eps=103,min_samples=2

二、分析

DBSCAN 算法的基本思路:

- 1. 给定数据点集合 D, 邻域半径 eps, 以及最小数目 min samples。 生成簇标识 C
- 2. 选取一个未被标记的数据点 p, 判断该数据点是否为核心对象, 若是核心对象则跳 到步骤 3, 否则 4
- 3. 将数据点 p 密度可达的所有数据点标记为 C,表明这些数据点已被分类且属于簇 C
- 4. 若数据点 p 是噪声点,将 p 标记为噪声点,否则标记为非噪声点的非核心对象
- 5. 更新簇标识 C, 跳回 2, 直到所有数据点被标记

本题中 eps 和 min_samples 的值都非常难确定,在调参数的过程中,我发现,当 min_samples 的值确定的前提下,其 silhouette 参数会随着 eps 的增加而增加,所以我 试着把生成的簇的个数打印出来之后,发现当且仅当 min_samples = 2 时,才有可能出 现两个以上的簇。而假设 min_samples=2,且簇的个数必须为两个以上,从打印出的结果来看当 eps=103 时,silhouette 参数能够取到最大值 0.18。

(一) 取 KNN 的结果进行验证分析

当 eps=102,min_samples=2,簇的个数为 2 时,取 KNN 的结果验证,由最上面第二图可知验证通过。但是 silhouette 参数比较小,而且考虑到第二题中的出现问

题,为了进一步分析,我将此时样本的标签打印出来:

可以看到样本中出现了大量的噪点,结合之前第二题的结论,可能是由于数据源中大量数据相似,只有少量噪点数据。为了验证这一点,我取 k=4,eps=300 (k=4 时簇的个数为 1, eps=300 保证 silhouette 足够大)并查看结果:

```
0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
          0 0 0
0 0 0 0 0 0 0 0 0
     0 0 0 0
        0
        0
         0
```

可知此时只有少量的噪点,簇个数为 1, 所以数据源中大量数据相似,只有少量噪点数据这个猜想是正确的。

(二) 和 KMeans 的最优结果进行比较

基于前面的分析,当簇的个数为1时,DBSCAN 不存在最优情况;所以我就拿 簇为2的时候的最优解和 KMeans 最优解进行比较。

由第二题可知:

- KMeans_silhouette = 0.94 > DBSCAN_silhouette = 0.18
- KMeans time = 0.275 < DBSCAN time = 0.8

而且 KMeans 中样本标签的情况如图:

很明显,在相同条件下,DBSCAN 的结果没有 KMeans 的效果好,原因可能是因为: DBSCAN 算法需要通过比较样本与样本之间的距离来确定聚类的,对于二维空间的点,可以使用欧几里得距离来计算,而对于很高维度的数据集,对其距离的定义会非常困难,而这次使用的数据正是维度很高很高,因此导致聚类效果差。

三、性能

可以看出 DBSCAN 花了大量的时间,可能是由于数据量较大,而且数据维度高,DBSCAN 要求较大的内存支持,I/O 消耗也很大。

